


ANALYSE EXPLORATOIRE




Dépendances entre variables

15/04/2026

INTRODUCTION



Suivi foetal



CARDIOTOCOGRAPHIE

Rythme cardiaque foetal

Contractions utérines



**Évalue le bien-être du
fœtus en temps réel**

MATERIELS & METHODES

Dataset : <https://archive.ics.uci.edu/dataset/193/cardiotocography>

Base UCI Machine Learning Repository avec 2129 observations.

	b	e	AC	FM	UC	DL	DS	DP	DR	Unnamed: 9	...	E	AD	DE	LD	FS	SUSP	Unnamed: 42	CLASS	Unnamed: 44	NSP
0	240.0	357.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	NaN	...	-1.0	-1.0	-1.0	-1.0	1.0	-1.0	NaN	9.0	NaN	2.0
1	5.0	632.0	4.0	0.0	4.0	2.0	0.0	0.0	0.0	NaN	...	-1.0	1.0	-1.0	-1.0	-1.0	-1.0	NaN	6.0	NaN	1.0
2	177.0	779.0	2.0	0.0	5.0	2.0	0.0	0.0	0.0	NaN	...	-1.0	1.0	-1.0	-1.0	-1.0	-1.0	NaN	6.0	NaN	1.0
3	411.0	1192.0	2.0	0.0	6.0	2.0	0.0	0.0	0.0	NaN	...	-1.0	1.0	-1.0	-1.0	-1.0	-1.0	NaN	6.0	NaN	1.0
4	533.0	1147.0	4.0	0.0	5.0	0.0	0.0	0.0	0.0	NaN	...	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	NaN	2.0	NaN	1.0

Démarches en 3 étapes :

- Analyse univariée
- Analyse multivariée
- Focus sur certaines techniques

1. ANALYSE UNIVARIÉE :

a) Nettoyage

Avant nettoyage :

Détection valeurs manquantes
pd.isna(df)
✓ 0.0s

	b	e	AC	FM	UC	DL	DS	DP	DR	LB	...	C	D	E	AD	DE	LD	FS	SUSP	CLASS	NSP
0	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
1	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
2	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
3	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
4	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
2124	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
2125	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
2126	True	True	True	True	True	True	True	True	True	True	...	True	True	True	True	True	True	True	True	True	True
2127	True	True	True	True	True	False	False	False	False	True	...	False	False	False	False	False	False	False	False	True	True
2128	True	True	True	False	False	False	False	False	False	True	...	True	True	True	True	True	True	True	True	True	True

2129 rows × 42 columns

1. ANALYSE UNIVARIÉE :

a) Nettoyage

Après nettoyage :

```
# Seulement 3 lignes ont au moins 1 valeur manquante, nous décidons de supprimer l'instance entière
df_valid=df.dropna()
pd.isna(df_valid)
✓ 0.1s
```

	b	e	AC	FM	UC	DL	DS	DP	DR	LB	...	C	D	E	AD	DE	LD	FS	SUSP	CLASS	NSP
0	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
1	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
2	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
3	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
4	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
2121	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
2122	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
2123	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
2124	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
2125	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False

2126 rows x 42 columns

1. ANALYSE UNIVARIÉE :

b) Statistiques descriptives

df.describe()
✓ 0.1s

	b	e	AC	FM	UC	DL	DS	DP	DR	LB	...	C
count	2126.000000	2126.000000	2126.000000	2127.000000	2127.000000	2128.000000	2128.000000	2128.000000	2128.0	2126.000000	...	2127.000000
mean	878.439793	1702.877234	2.722484	7.503056	3.669017	1.576128	0.003759	0.127820	0.0	133.303857	...	-0.924777
std	894.084748	930.919143	3.560850	39.030452	2.877148	2.517794	0.061213	0.471687	0.0	9.840844	...	1.210639
min	0.000000	287.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.0	106.000000	...	-1.000000
25%	55.000000	1009.000000	0.000000	0.000000	1.000000	0.000000	0.000000	0.000000	0.0	126.000000	...	-1.000000
50%	538.000000	1241.000000	1.000000	0.000000	3.000000	0.000000	0.000000	0.000000	0.0	133.000000	...	-1.000000
75%	1521.000000	2434.750000	4.000000	2.000000	5.000000	3.000000	0.000000	0.000000	0.0	140.000000	...	-1.000000
max	3296.000000	3599.000000	26.000000	564.000000	23.000000	16.000000	1.000000	4.000000	0.0	160.000000	...	53.000000


8 rows x 42 columns

1. ANALYSE UNIVARIÉE :

c) Visualisation globale

Variables cibles :


- **LB** → fréquence cardiaque
- **UC** → contractions utérines
- **NSP** → classes :
 - sain : 1
 - suspect : 2
 - pathologique : 3




1. ANALYSE UNIVARIÉE :

d) Normalité

LB




UC




1. ANALYSE UNIVARIÉE :

Distributions :



2. ANALYSE MULTIVARIÉE :

Cas 2 : NSP ↔ LB ou UC (catégorielle/quantitative)




Variable LB

- NSP = 1 (Normal) : médiane ≈ 133
- NSP = 2 (Suspect) : médiane ≈ 144
- NSP = 3 (Pathologique) : médiane ≈ 132-133

Variable UC

- NSP = 1 (Normal) : médiane ≈ 4
- NSP = 2 (Suspect) : médiane ≈ 1
- NSP = 3 (Pathologique) : médiane ≈ 2-3



**Problématique : Comment déterminer s'il y a
une dépendance entre 2 variables et quand
appliquer ces méthodes ?**

État de l'art :

type de variables	Méthodes/Tests	Quand l'utiliser ?	Conditions
Quantitatives <-> Quantitatives	Pearson, Spearman, Kendall, matrice de corrélation/heatmap.	Démontrer une relation linéaire entre 2 variables numériques	Normalité et si échantillon très grand pas besoin de vérifier.
Catégorielles <-> Catégorielles	Khi-2	Tester l'indépendance entre 2 variables quantitatives via une table de contingence.	Effectif.
Quantitatives <-> Catégorielles	ANOVA, Kruskal-Wallis, Tukey, Dunn (correction de Bonferroni)	Comparer la distribution d'une variable quantitative (LB et UC) entre k groupes définis par la variable catégorielle (NSP)	Normalité pour ANOVA.
Tout type	Information mutuelle	Détecter des relations non linéaires/complexes et indépendantes du type de variables.	Ø

2.ANALYSE MULTIVARIÉE - ANALYSE DES DÉPENDANCES

Corrélation - Cas 1 : LB ↔ UC (quantitative/quantitative)


Corrélation :

```
df_cible = df_valid[["LB", "UC", "NSP"]].copy()
corr = df_cible.iloc[:, :-1].corr()
corr
```

✓ 0.1s

	LB	UC
LB	1.000000	-0.127722
UC	-0.127722	1.000000

Heatmap :



Pas de corrélation linéaire
entre LB et UC

Pearson :

```
p_corr = masked_corr.copy()
for (row, col) in zip(p_corr.index, p_corr.columns):
    p_corr.loc[row, col] = scipy.stats.pearsonr(corr[row], y=corr[col]).pvalue
p_corr
```

	LB
UC	1.0

→ **p-value > 0.05**

2. ANALYSE MULTIVARIÉE - ANALYSE DES DÉPENDANCES

Corrélation - Cas 2 : NSP ↔ LB ou UC (catégorielle/quantitative)

→ Étant donné que la distribution ne suit aucune loi de normalité, nous effectuons le test de Kruskal-Wallis.

```
from scipy import stats

df_kw = df_valid.copy()
lb1 = df_kw.loc[df_kw["NSP"] == 1, "LB"]
lb2 = df_kw.loc[df_kw["NSP"] == 2, "LB"]
lb3 = df_kw.loc[df_kw["NSP"] == 3, "LB"]

uc1 = df_kw.loc[df_kw["NSP"] == 1, "UC"]
uc2 = df_kw.loc[df_kw["NSP"] == 2, "UC"]
uc3 = df_kw.loc[df_kw["NSP"] == 3, "UC"]

kw_lb = stats.kruskal(lb1, lb2, lb3)
kw_uc = stats.kruskal(uc1, uc2, uc3)

print("Kruskal-Wallis LB ~ NSP :", kw_lb)
print("Kruskal-Wallis UC ~ NSP :", kw_uc)
```

- LB ~ NSP : pvalue = 5.917588127255909e-56

- UC ~ NSP : pvalue = 5.6647708129373e-35

→ pvalue <<< 0.05 donc différence significative de distributions / dépendance

Le test de Kruskal-Wallis montre une différence significative de la distribution de LB (ou UC) selon les classes NSP, ce qui suggère une dépendance entre LB (ou UC) et l'état foetal.

2.ANALYSE MULTIVARIÉE - ANALYSE DES DÉPENDANCES

Corrélation - Cas 2 : NSP ↔ LB ou UC (catégorielle/quantitative)

→ Comparaisons pair à pair = Test de Dunn.

```
import scikit_posthocs as sp

# Dunn pour LB
dunn_lb = sp.posthoc_dunn(
    df_kw,          # dataframe complet
    val_col="LB",    # variable numérique
    group_col="NSP", # groupe
    p_adjust="bonferroni" # ou "holm"
)
print("Dunn (LB ~ NSP) :")
print(dunn_lb)

# Dunn pour UC
dunn_uc = sp.posthoc_dunn(
    df_kw,
    val_col="UC",
    group_col="NSP",
    p_adjust="bonferroni"
)
print("Dunn (UC ~ NSP) :")
print(dunn_uc)
```



Dunn (LB ~ NSP) :			
	1.0	2.0	3.0
1.0	1.000000e+00	2.057198e-55	1.000000e+00
2.0	2.057198e-55	1.000000e+00	2.260698e-27
3.0	1.000000e+00	2.260698e-27	1.000000e+00
Dunn (UC ~ NSP) :			
	1.0	2.0	3.0
1.0	1.000000e+00	1.189418e-33	0.000020
2.0	1.189418e-33	1.000000e+00	0.000044
3.0	1.989122e-05	4.438677e-05	1.000000

2. ANALYSE MULTIVARIÉE - ANALYSE DES DÉPENDANCES

Information mutuelle : NSP ↔ LB ou UC (catégorielle/quantitative)

```
from sklearn.feature_selection import mutual_info_classif
import pandas as pd

# X = variables explicatives (numériques)
X = df_valid[["LB", "UC"]]
y = df_valid["NSP"] # cible catégorielle

mi = mutual_info_classif(X, y, discrete_features=False, random_state=0)

mi_series = pd.Series(mi, index=X.columns).sort_values(ascending=False)
print(mi_series)
```

✓ 3.9s

```
LB    0.127525
UC    0.059715
dtype: float64
```


MI(LB) > MI(UC)

→ LB apport davantage d'information sur NSP que UC, ce qui va nous servir pour la suite de notre étude...

DISCUSSION/CONCLUSION

- Dépendances entre UC et LB :

→ Vérification corrélation linéaire de Pearson :



Pas de corrélation linéaire.


- Dépendances entre UC $\leftarrow$ NSP $\rightarrow$ LB :

→ Test non-paramétrique Kruskal-Wallis puis Dunn



Dépendances entre variables.

→ Information mutuelle



LB apporte davantage
d'information sur la classe NSP
qu'UC

Perspectives :

- Voir s'il existe d'autres variables pouvant être prises en compte pour le bien être foetal, à part UC et LB.
- Avec la régression logistique, tester pour prédire NSP en fonction de LB.



**MERCI DE VOTRE
ATTENTION !**

